

비트코인 수익률 변동성 예측을 위한 LSTM 기반 통합 모델 연구

A Study on an Integrated LSTM-Based Model for Predicting Bitcoin Return Volatility

김수빈
손수빈
황금빈

지도 교수 : 송 재 욱 (인)

심사위원 교수 : (인)

한양대학교 산업공학과

국문 초록

본 연구에서는 비트코인 4시간 단위 종가 데이터를 활용하여 일주일간 이동 표준편차를 예측하는 LSTM 통합 모델을 구축하고 평가하였다. 독립 변수로는 GARCH(1,1), EGARCH(1,1) 모델의 조건부 변동성, GARCH(1,1) 모델의 예측값, 경제 지표의 이동 표준편차를 사용하였다. 실험은 세 단계로 진행되었으며, LSTM 단일 모델의 성능 개선 여부, 동일한 파라미터 조합 내의 다른 모델 간 성능 비교, 최적의 파라미터 조합 도출을 평가하였다. 결과적으로, LSTM-GARCH-EGARCH 모델이 가장 높은 성능을 보였고, 최적의 설명 변수 조합은 모델마다 다를 것을 확인하였다.

주 용어: 비트코인, 변동성, LSTM, GARCH, EGARCH

목차

그림 목차	4
표 목차	5
1. 서론	6
2. 문헌 고찰	7
3. 데이터 및 방법론	8
3.1 데이터	8
3.2 Framework	11
3.3 금융시계열 변동성 모형	11
3.3.1 GARCH(1,1) 모형	11
3.3.2 EGARCH(1,1) 모형	12
3.3.3 GARCH-EGARCH 통합 모형 소개	12
3.4 인공신경망 모형	13
3.4.1 순환신경망	13
3.4.2 장단기 기억	13
3.5 LSTM과 금융시계열 변동성 모형을 이용한 통합모델 제안	15
3.6 평가지표 및 측정	17
3.6.1 Root Mean Squared Error	17
3.6.2 Heteroscedastic Mean Absolute Error	17
3.6.3 역사적 변동성	18
4. 실험 및 평가	18
4.1 모델 별 경제지표 설명변수 투입 여부에 따른 예측 성능 개선 평가	19
4.1.1 LSTM 단일 모델	19
4.1.2 LSTM 기반 모델 전체	21
4.2 모델 간 변동성 예측 성능 평가	22
4.3 모델 별 입력변수 조합에 따른 예측 성능 평가 및 최적 조합 제안	25
4.3.1 LSTM-GARCH 모델	25
4.3.2 LSTM-EGARCH 모델	26
4.3.3 LSTM-GARCH-EGARCH 모델	27
5. 결과	30
6. 참고문헌	31
Abstract	32

그림 목차

1. <Figure 1> Log-differenced returns of Bitcoin closing price data -----	10
2. <Figure 2> Histogram of log-differenced returns of Bitcoin closing price data -----	11
3. <Figure 3> Experimental structure of this study -----	12
4. <Figure 4> LSTM structure -----	17
5. <Figure 5> LSTM-GARCH-EGARCH structure -----	18
6. <Figure 6> Correlation matrix -----	25
7. <Figure 7> Target value vs. Predicted target value plot for LSTM model -----	27
8. <Figure 8> Target value vs. Predicted target Value plot for each hybrid model -----	27
9. <Figure 9> Volatility prediction results (LSTM-GARCH model) -----	28
10. <Figure 10> Volatility prediction results (LSTM-EGARCH model) -----	28
11. <Figure 11> Volatility prediction results (LSTM-EGARCH model) -----	29
12. <Figure 12> RMSE vs. epochs plot of the model that showed the best RMSE statistical performance -----	30
13. <Figure 13> RMSE vs. epochs plot of the model that showed the best RMSE statistical performance -----	32
14. <Figure 14> RMSE vs. epochs plot of the model that showed the best RMSE statistical performance -----	33

표 목차

1. <Table 1> Unit root test of log-differenced returns for 4-hour Bitcoin closing price data -----	10
2. <Table 2> Normality test results : Jarque-Bera -----	11
3. <Table 3> Heteroscedasticity test results : ARCH-LM -----	11
4. <Table 4> Input and output variables -----	12
5. <Table 5> An overview of the LSTM-based model -----	23
6. <Table 6> Comparison of LSTM single models based on different combinations of economic indicators -----	23
7. <Table 7> Model performance improvement rates with the addition of each explanatory variable -----	24
8. <Table 8> Performance evaluation of models with and without economic indicators -----	26
9. <Table 9> Statistical performances for each model based on volatility range -----	27
10. <Table 10> Statistical performance results for all combinations of explanatory variables -----	29
11. <Table 11> Best predictive performance explanatory variable combination for LSTM-GARCH model based on RMSE and HMAE -----	30
12. <Table 12> Statistical performance results for all combinations of explanatory variables -----	31
13. <Table 13> Best predictive performance explanatory variable combination for LSTM-EGARCH model based on RMSE and HMAE -----	31
14. <Table 14> Statistical performance results for all combinations of explanatory variables -----	32
15. <Table 15> Best predictive performance explanatory variable combination for LSTM-GARCH-EGARCH model based on RMSE and HMAE -----	33
16. <Table 16> Best predictive performance explanatory variable combination for all models based on RMSE -----	34

1. 서론

한국의 금융 시장은 전통적으로 주식, 채권, 부동산 등의 자산이 주류를 이루어왔으나, 최근 몇 년 동안 비트코인을 비롯한 암호화폐의 등장이 금융 시장에 큰 변화를 가져왔다. 특히 2017년부터 비트코인의 가격이 급등하면서 한국의 많은 투자자들이 비트코인에 관심을 가지게 되었고, 이에 따라 암호화폐 거래소들도 급증하였다. 한국은 암호화폐 거래의 활발한 중심지 중 하나로 자리매김했으며, 전체 비트코인 거래량의 상당 부분이 한국에서 발생하고 있다. 이러한 환경 변화는 금융 시장의 구조를 재편하고, 투자자들의 투자 패턴에도 큰 영향을 미치고 있다.

비트코인은 단순한 디지털 화폐의 개념을 넘어 투자 자산으로서의 역할을 강화하고 있다. 비트코인은 현재 담보 대출 서비스의 기본 자산으로 사용되기도 하며, 금을 대신하는 실물 자산 기능으로써 주목받고 있다. 이는 비트코인이 높은 유동성과 제한된 공급량으로 인해 가치 저장의 수단으로 인식되고 있음을 의미한다. 비트코인의 이러한 특성 때문에 많은 투자자들이 포트폴리오 다변화의 일환으로 비트코인을 포함시키고 있으며, 이로 인해 비트코인의 가격 변동성 예측은 중요한 연구 주제가 되고 있다.

비트코인의 가격은 다른 전통적인 자산에 비해 매우 높은 변동성을 보인다. 비트코인의 변동성이 높은 이유는 여러 가지가 있다. 비트코인의 시장 규모가 상대적으로 작아 대규모 거래가 가격에 큰 영향을 미칠 수 있다. 또한, 비트코인은 규제 환경이 불확실하여 정책 변화나 정부의 규제 강화에 민감하게 반응한다. 규제를 비롯하여 비트코인의 가치는 기술적 발전, 보안 이슈, 해킹 사건 등의 외부 요인에 크게 영향을 받는다. 마지막으로, 투자자들의 심리적 요인도 큰 역할을 한다. 비트코인 시장은 여전히 투기적인 성격이 강해 투자자들의 감정에 따라 가격이 급등락할 수 있다.

이와 같은 이유로 비트코인의 가격 변동성을 정확하게 예측하는 것은 투자자들에게 매우 중요한 과제가 되었다. 그러나, GARCH type 단일 모델로 수행한 비트코인의 변동성 예측 성능은 좋지 않았으며 (Kim and Jung, 2022), 예측력을 높이기 위해서는 더 많은 정보를 학습할 수 있는 딥러닝 모델이 필요할 것으로 보인다. 따라서 본 연구에서는 LSTM 기반 통합 모델을 통해 비트코인의 수익률 변동성을 예측하고, 이를 통해 투자자들에게 유용한 정보를 제공하고자 한다. LSTM을 주 예측 모형으로 삼고 GARCH type 모형의 적용으로 얻는 시계열 예측 값을 새로운 변수로 활용하였다. 궁극적으로, 어떤 추가적인 변수를 활용했을 때 수익률 변동성 예측력이 향상되는지 비교하여, 후속 연구의 초석을 마련하고자 한다.

본 연구는 Upbit 거래소의 2020년 1월 1일 0시부터 2024년 4월 9일 5시까지의 4시간 단위 비트코인 종가 데이터를 수집하였다. 4시간 단위의 데이터를 이용함으로써 더 많은 데이터를 기반으로 예측 모델을 구축하고자 하였다. 이를 통해 일별 변동성보다 더 세밀한 시간 단위에서 시장의 움직임을 포착하는 것을 목표로 하였다.

이렇게 구축된 모델은 현재 시점에서의 4시간 단위 변동성을 예측하는 데 활용될 수 있을 것으로 기대된다. 예측한 변동성 데이터는 더 정교한 투자 전략 수립에 기여할 수 있으며, 투자 포트폴리오의 리스크 관리에도 유용하게 사용될 수 있을 것이다. 특정 시간대에 높은 변동성이 예상되는 경우, 투자자들은 해당 시간대에 대한 포트폴리오 조정을 통해 잠재적인 손실을 최소화할 수 있을 것이다.

본 연구의 구성은 다음과 같다. 2장에서는 비트코인 관련 선행 연구를 고찰하며 본 연구가 지니는 차

별점에 관해 언급한다. 3장에서는 본 논문에서 사용한 변수 및 방법론을 설명하며, 4장에서는 본 논문에서 진행한 실험에 관해 설명한다. 5장에서는 실험 결과에 대해 분석하며, 마지막 장에서는 요약 및 연구의 한계, 비트코인 후속 연구에 대해 제안한다.

2. 문헌 고찰

비트코인과 관련된 연구 주제의 경우, 비트코인 변동성과 특정 경제 지표 변수간에 어떤 관련성이 있는지에 대해 많은 연구가 진행되어왔다. 두 대상 사이의 상관관계가 존재하면, 비트코인은 금과 유사한 안전자산의 기능을 할 것으로 기대된다. 기존 선행 논문에서는 비트코인과 경제 지표들 간의 상관관계를 분석하였다. 비트코인 가격에 영향을 미치는 경제적 요인을 분석하기 전 본 연구에 활용할 달러지수, 원 달러 환율 변화율, 금 가격 변화율, KOSPI 수익률, KOSPI 개인 순매수비율, KOSPI 기관 순매수비율 변수는 모두 통계적으로 비트코인 가격 변화율과 유의하지 않음을 확인하였다(Lee et al, 2019). 결론적으로, 해당 시기의 비트코인 가격이 대체로 미국 달러나 금, 또는 주식시장에 대한 투자와 개별적으로 움직였을 것으로 예상할 수 있다. 비트코인의 안전자산 여부를 판별하기 위해 비트코인과 경제 지표들 간의 상관관계를 분석한 결과, 사용된 경제 지표는 미달러화 지수, 국제유가, 유로화 환율, 미국채 10년 물 금리, VIX 지수, S&P500 지수였다(Son and Kim, 2019). 6가지 경제 변수와의 단순 회귀분석 및 그랜저 인과관계 분석 결과 비트코인의 경우 변수들과 인과관계가 성립하지 않았다.

비트코인 변동성과 경제 지표와의 상관성 분석 외에도, GARCH type 단일 모델을 활용해 비트코인의 수익률 변동성을 예측한 연구가 진행되었다. GARCH, EGARCH, TGARCH 등 6가지의 GARCH류 모델을 활용하여 2017년 9월 25일부터 2021년 7월 25일까지 Coindesk와 Upbit 거래소별 비트코인의 가격 변화의 특성을 연구한 결과, 거래소마다의 비트코인 가격 변화를 설명하는 공통된 GARCH type 모형은 존재하지 않았다(Kim and Jung, 2018). Coindesk 시장에서는 EGARCH모형이 비트코인 가격변동성을 잘 설명하는 모형으로 제시되었으며, Upbit 시장에서는 CGARCH모형이 비트코인 가격변동성을 잘 설명하는 모형으로 나타났다. 또한, 글로벌 규제가 상대적으로 없었던 2017년 이전 Coindesk의 비트코인 가격에 대해서는 CGARCH모형이 설명력이 높고 적합하였으나, 글로벌 규제가 2차례 있었던 2017년 이후는 장단기 변동성을 구분하는 CGARCH모형이 적합한 것으로 나타났다. 결론적으로, 비트코인 가격변화를 분석하는데 있어 전통적인 GARCH류 단일 모델은 예측력이 충분하지 않았다. 해당 연구에서는 왜도, 두터운 꼬리, 점프, 장기 의존성, 체제변동성, 다중프랙탈 등을 고려한 모형으로 발전되어야 할 필요성을 제시하였다.

한편, 딥러닝 모델을 사용해서 기초 자산의 변동성을 예측하려는 시도가 이어지고 있다. LSTM(Long Short Term Memory)을 활용한 연구들은 특히 주목받고 있다. LSTM 모델을 사용하여 과거 데이터를 기반으로 KOSPI, S&P 500, NIKKEI 225 등의 미래 30일간의 변동성을 예측하는 방법에 대한 연구가 제안된다(Song et al, 2019). 해당 연구에서는 각 종가의 30일 이동평균, 30일 모멘텀, GARCH(1,1)모형 결과 값, 30일 표준편차를 독립변수로 사용하였다. 연구 결과, 모델이 예측한 변동성 움직임은 동일한 기간 동안의 실제 변동성 값과 상당히 유사하였다.

딥러닝 모델과 여러 종류의 GARCH type 모델을 함께 활용하여 변동성을 예측하는 통합 모델이 제시되기도 하였다. 미국의 대표적인 지수인 S&P500 지수 변동성을 LSTM과 GARCH type 모델을 융합시켜 예측한 연구를 진행한 결과, LSTM을 GARCH-type 모델 3개와 결합한 GEW-LSTM (GARCH EGARCH EWMA-LSTM)이 LSTM 단일 모델 및 GARCH type 모델 각각의 성능 지표보다 앞서는 것을

알 수 있었다(Kim and Won, 2018). LSTM과 다중 GARCH-type 모델들을 합성시켰을 때 지수 변동성 예측력이 향상됨을 확인하였다.

선행 연구에서는 경제 지표와 비트코인 가격 변화율의 상관관계를 주로 분석하였다. 단순 회귀분석 및 상관분석은 선형적 관계의 존재 여부만을 판단할 수 있다는 한계가 있다. 따라서 경제 지표 변수가 비트코인과 선형적 관계 이외의 비선형적 연관성이 있을 수 있으며, 이러한 비선형적 관계를 탐구하기 위해, 보다 정교한 분석 기법이 필요하다. 본 연구에서는 그 연관성을 알아보기 위해, 딥러닝 모델을 선택하여 연구를 진행하였다. 선행 연구에서는 비트코인 변동성을 예측하기 위해 GARCH 유형의 단일 모델만을 사용하였으며, 비트코인 변동성에 LSTM과 GARCH type 통합 모델을 적용한 연구는 존재하지 않았다. 따라서, 본 연구에서는 LSTM 기반 GARCH type 통합 모델을 사용하여 비트코인의 수익률 변동성을 예측하고자 한다. GARCH 모델의 통계적 강점과 LSTM 모델의 정교한 예측 능력을 결합함으로써, 보다 정교하고 신뢰성 있는 예측을 하고자 한다. 이를 통해 비트코인 투자자들에게 유용한 정보를 제공하고, 향후 비트코인 시장의 안정성 향상에 기여하고자 한다.

3. 데이터 및 방법론

3.1 데이터

본 연구에서는 2020년부터 2024년 4월까지의 4시간 단위 비트코인 종가 데이터를 사용하였다. Upbit 거래소의 데이터를 활용하였다.

Table 1. Unit root test of log-differenced returns for 4-hour Bitcoin closing price data

ADF-test	statistic	-14.511
	p-value	0.000
Critical Value	1% Level	-3.431
	5% Level	-2.862
	10% Level	-2.567

비트코인 종가 로그 수익률의 ADF 테스트 결과는 <Table 1>과 같다. 따라서 비트코인 4시간 단위 로그 수익률 데이터는 정상성을 가지며, 이를 기반으로 한 시계열 모델은 적절하다는 결론을 내릴 수 있다.




Figure 1. Log-differenced returns of Bitcoin closing price data

〈Figure 1〉을 보면, 비트코인의 로그 수익률이 시간에 따라 변동성이 높은 구간과 낮은 구간이 번갈아 나타나는 변동성 클러스터링 현상이 관찰됨을 확인할 수 있다. 이는 변동성이 예측 가능한 패턴으로 움직인다는 것을 의미하고, 이런 패턴을 이용하면 변동성을 보다 정확히 예측할 수 있음을 시사한다.




Figure 2. Histogram of log-differenced returns of Bitcoin closing price data

〈Figure 2〉에서 비트코인 로그 수익률 분포의 형태는 꼬리가 두껍고 약간의 비대칭성이 있는 것을 확인할 수 있다. 이를 더 정확하게 판단하기 위해서 Jarque-Bera 검정을 통해 데이터의 정규성을 확인하였다.

Table 2. Normality test results : Jarque-Bera

Jarque-Bera	Statistic	p-value
	84241.368	0.000

Jarque-Bera 검정 결과는 〈Table 2〉와 같다. 데이터가 정규분포를 따른다는 귀무가설은 5%의 유의 수준으로 기각된다. 이는 4시간 단위 비트코인 로그 수익률 데이터가 정규분포를 따르지 않는다는 것을 의미한다. 고로, 데이터는 왜도와 첨도를 가지고 있으며 정규분포와는 다른 분포를 보이기 때문에 시계열 상에 종속성이나 이분산성이 존재할 수 있다고 가정할 수 있다. 〈Table 3〉과 같이 ARCH-LM Test를 통해 이분산성의 유무를 검증하였다.

Table 3. Heteroscedasticity test results : ARCH-LM

ARCH-LM	F-test value	p-value
	1164.614	0.000

ARCH-LM 검정의 잔차가 등분산성을 가진다는 귀무가설은 5%의 유의수준으로 기각되므로, 잔차가 조건부 이분산성을 가진다고 할 수 있다. 따라서 비트코인 로그 수익률 데이터는 ARCH, GARCH 등 이분산성을 가정하는 시계열 변동성 예측모형에 적합하다는 결론을 내릴 수 있다. 이러한 결과를 토대로, 해당 데이터에 GARCH type 모형을 적합하여 LSTM 통합 모델 연구를 수행한다.

분석을 위한 독립 및 종속변수 정의는 〈Table 4〉와 같다.

Table 4. Input and output variables

Variable Type	Factor	Explanation
Input	Predicted_volatility	Predicted values from a GARCH(1,1) model fitted to the previous 42 time points
Input	USD_KRW_vol	Rolling standard deviation of the past week of closing exchange rates
Input	KOSPI200_vol	Rolling standard deviation of the past week of the closing KOSPI200 index
Input	CBOE_VIX_vol	Rolling standard deviation of the past week of the closing VIX index
Input	GARCH(1,1)	Conditional volatility from a GARCH(1,1) model
Input	EGARCH(1,1)	Conditional volatility from an EGARCH(1,1) model
Output	Historical_volatility	Rolling standard deviation of the 4-hour Bitcoin closing prices over the past week

모든 경제 지표 데이터의 경우 과거 일주일간의 이동 표준편차를 적용하여 독립변수로 활용하였다. 경제 지표 값 자체를 모델에 활용하는 것이 아닌, 과거의 데이터로부터 계산된 이동 표준편차를 활용하였다. 이는 변동성 예측이라는 연구의 목적을 보다 정확하게 반영하기 위함이며, 최근 시장 트렌드를 포함한 변동성을 효과적으로 반영할 수 있도록 하기 위함이다. 비트코인 시장은 24시간 운영되기 때문에 VIX 지수와 KOSPI200 지수와 같은 주식 시장 관련 지표는 정확한 시점에서 대응되지 않았다. 따라서 주식 시장이 개장되지 않은 시간대의 비트코인 데이터에 대해서는, 가장 최근의 경제지표 값을 사용하여 전처리하였다. GARCH(1,1)와 EGARCH(1,1)는 모델이 특정 데이터셋에 과적합되는 것을 방지하고 일반화된 성능을 얻기 위해, 훈련, 검증, 테스트 데이터셋 각각에 대해 별도로 적합하여 조건부 변동성을 구하였다.

경제지표 변수의 이동 표준편차를 계산하는 과정에서 로그 수익률을 적용하였다. 로그 수익률 계산식은 수식 (1)과 같다.

$$X = \log(P_t) - \log(P_{t-1}) \quad (1)$$

P_t 는 $t-1$ 번째 시점의 경제지표를 의미하며, P_{t-1} 은 $t-1$ 번째 시점의 경제지표 값을 의미한다. 수식 (2)는 이동 표준편차를 구하는 식이다.

$$\sigma_t = \sqrt{\frac{1}{w} \times \sum_{i=t-w+1}^t (X_i - \mu_i^2)} \quad (2)$$

수식 2를 살펴보면, 해당 시점의 로그수익률인 X_i 와, 전체 데이터 포인트 수인 n , window 크기인 w 으로 구성되어 있다. μ_i 는 i 시점의 이동 평균에 해당한다.

3.2 Framework

본 연구의 framework는 다음과 같다.




Figure 3. Experimental structure of this study

본 연구는 LSTM 단일 모델, GARCH-LSTM 모델, EGARCH-LSTM 모델, GARCH-EGARCH-LSTM 모델 간의 성능을 비교한다. 각 모델은 경제 지표의 과거 일주일간의 변동성 값을 독립 변수로 포함하며, 이를 통해 성능을 평가한다. 또한, 각 모델에 대해 최적의 변수 조합을 찾는 방향으로 실험을 진행한다.

3.3 금융 시계열 변동성 모형

3.3.1 GARCH(1,1) 모형

GARCH(Generalized Autoregressive Conditional Heteroskedasticity) 모형은 금융 시계열 데이터의 변동성을 예측하기 위해 가장 널리 사용되는 방법 중 하나이다. Engle(1982)이 처음 제안한 ARCH(AutoRegressive Conditional Heteroskedasticity) 모형을 Bollerslev(1986)에서 확장하여 GARCH 모형을 개발하였다. 이 모형은 시계열의 조건부 분산이 과거의 오차항과 조건부 분산의 함수로 표현될 수 있다고 가정한다.

본 연구에서 사용할 모형은 GARCH(1.1) 모형으로 평균 방정식과 조건부 분산 방정식으로 나타낼 수 있다. 평균 방정식은 시계열 데이터의 값을 예측하고, 조건부 분산 방정식은 변동성을 예측한다. 관련 식은 수식 (3)과 수식 (4)이다.

$$y_t = a + by_{t-1} + \epsilon_t \quad (3)$$

$$\sigma_t^2 = \omega + \alpha\epsilon_{t-1}^2 + \beta\sigma_{t-1}^2 \quad (4)$$

y_t 는 시계열 데이터의 현재 값으로, 본 연구에서는 현재 비트코인의 수익률을 의미한다. y_{t-1} 는 시계열 데이터의 이전 값이며, 직전 시점의 비트코인의 가격을 의미한다. ϵ_t 는 오차항(충격)으로, 평균 방정식에서 예측되지 않은 변동을 나타낸다. 이는 정규분포를 따르며, $\epsilon_t \sim N(0, \sigma_t^2)$ 이다. σ_t^2 는 현재 시점 t 의 조건부 분산 (변동성)을 나타낸다. 본 연구에서는 현재 시점의 오차항의 분산으로 해석된다. ω 는 조건부

분산의 절편을 나타내며 기본적인 변동성 수준을 의미한다.

GARCH(1,1) 모형은 금융 시계열 데이터의 변동성을 보다 정확하게 예측하기 위해 과거의 오차항과 변동성을 모두 고려한다. 이는 큰 변동성이 한 시점에 발생하면 그 이후에도 큰 변동성이 계속 나타나는 군집 경향을 설명하는 데 유용하다. GARCH(1,1) 모형은 레프토크시스(leptokurtosis)와 변동성 클러스터링을 모두 포착한다. GARCH(1,1) 모형은 오차항의 분산이 일정하지 않고, 과거의 충격과 분산의 함수로 변화한다고 가정한다. 이를 통해 시계열 데이터의 변동성을 보다 현실적으로 모델링할 수 있다고 판단한다. GARCH(1,1) 모형은 과거의 수익률과 변동성을 이용하여 미래의 변동성을 예측한다. 비트코인 투자자들이 수익률 변동성을 이해하고 위험을 관리할 수 있다는 점에서 본 연구에 유의미한 결과를 가져올 수 있는 모델이라 판단된다. 다만 변동성의 주요한 양식화 된 측면으로 여겨지는 시간 의존적 비대칭성은 반영이 안 되곤 한다(Kim and Won, 2018). 따라서 본 연구에서는 모형의 한계로서 GARCH 모형의 충격의 크기는 고려하지만, 방향은 고려하지 않는 방식으로 해석한다.

3.3.2 EGARCH 모형

EGARCH(Exponential GARCH) 모형은 Nelson(1991)이 제안한 모형으로, 충격의 크기에만 의존하며 음의 충격과 양의 충격을 동일하게 취급하는 GARCH 모형과는 다르게, 비대칭적 충격을 고려하여 음의 충격이 양의 충격보다 더 큰 영향을 미칠 수 있도록 한다. 이 모형의 로그 형태에서 파라미터는 양의 조건부 분산을 유지하면서도 제약을 받지 않을 수 있다. EGARCH 모형은 로그 조건부 분산을 사용하여 음수 값을 허용하고, 이때 조건부 분산은 충격의 방향과 크기를 모두 고려하여 정하게 된다.

EGARCH(1,1)의 조건부분산식은 수식 (5)와 같다.

$$\sigma_t^2 = \exp \left[\omega_0 + \beta \log(\sigma_{t-1}^2) + \alpha \left\{ \left| \frac{\epsilon_{t-1}}{\sigma_{t-1}} \right| - \sqrt{\frac{2}{\pi}} \right\} + \gamma \frac{\epsilon_{t-1}}{\sigma_{t-1}} \right] \quad (5)$$

식에서 ω_0 는 상수항으로, 로그 조건부 분산의 절편을 나타내며 기본적인 변동성 수준을 의미한다. 이때 ω 와 ω_0 사이에 발생하는 평균 효과를 상쇄하기 위해 다음과 같은 수식 (6)이 사용된다.

$$\omega = \omega_0 - \alpha \sqrt{\frac{2}{\pi}} \quad (6)$$

γ 는 비대칭 효과를 나타내는 계수로서 음의 충격과 양의 충격의 비대칭성을 설명한다. $\sqrt{\frac{2}{\pi}}$ 는 정규분포의 절댓값 기대값으로, 이를 통해 오차항의 표준화를 수행한다(Daniel B. Nelson, 1991).

3.3.3 GARCH-EGARCH 통합 모형 소개

GARCH-EGARCH 통합 모형은 GARCH와 EGARCH 각 모형의 장점을 결합하여 금융 시계열 데이터의 변동성을 예측하는 데 사용된다. 또한 GARCH-EGARCH 통합 모형은 보다 정교한 변동성 예측 모델을 구성할 수 있다고 언급된다(Kim and Won, 2018). 이 통합 모형은 GARCH 모형의 과거 충격과 분산의 의존성을 유지하면서 EGARCH 모형의 비대칭적 충격 효과를 동시에 고려하게 된다. 이는 비트

코인의 수익률 변동성을 더 정확하게 예측하고, 투자자들이 보다 효과적으로 위험을 관리할 수 있도록 도와주는 모형으로 기대된다.

수식 (7)은 GARCH-EGARCH 통합 모형의 조건부 분산 방정식이다.

$$\sigma_t^2 = \exp \left[\omega_0 + \beta \log(\sigma_{t-1}^2) + \alpha \left\{ \left| \frac{\epsilon_{t-1}}{\sigma_{t-1}} \right| - \sqrt{\frac{2}{\pi}} \right\} + \gamma \frac{\epsilon_{t-1}}{\sigma_{t-1}} \right] + \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \quad (7)$$

3.4 인공신경망 모형

3.4.1 순환신경망 (Recurrent Neural Networks, RNN)

순환신경망 (RNN)은 인공신경망의 일종으로, 시계열 데이터를 효과적으로 처리하기 위해 고안된 모델이다. 일반적인 신경망은 입력 데이터의 순서에 관계없이 학습을 진행하지만, RNN은 입력 데이터의 순서를 고려하여 학습한다. 이는 RNN이 이전 단계의 출력 값을 다음 단계의 입력으로 사용하기 때문에 가능하며, 이를 통해 시계열 데이터의 의존성을 모델링 할 수 있다. RNN의 구조는 시간축을 따라 반복되는 연결이 특징이며, 이는 데이터를 순차적으로 처리하여 출력값을 생성하고, 이 출력 값이 다음 단계의 입력에 영향을 미치게 한다.

그러나 RNN은 시퀀스가 길어질수록 학습이 진행되지 않는 기울기 소실(Vanishing Gradient) 문제를 겪게 된다. 이는 시간 단계가 길어질수록 초기 단계의 정보가 점차 소실되어 모델의 학습에 영향을 미치지 않게 되는 현상이다. 이러한 한계로 인해 RNN은 장기 의존성(Long-Term Dependencies)을 효과적으로 학습하기 어렵다.

3.4.2 장단기기억 (Long-Short-Term Memory, LSTM)

LSTM 은 RNN의 장기 의존성 문제를 해결하기 위해 Hochreiter and Schmidhuber(1997)에 의해 제안된 모델이다. LSTM은 순차 데이터(sequential data)를 처리하는 특정 유형의 RNN으로 정의된다. 메모리 셀과 다양한 게이트로 구성되어 있으며, 메모리 셀은 정보를 저장하고 게이트는 이를 업데이트한다(Kraus and Feuerriegel, 2017). LSTM은 셀 상태(Cell State)를 통해 장기 의존성을 유지하며, 입력 게이트(Input Gate), 망각 게이트(Forget Gate), 출력 게이트(Output Gate)를 추가하여 정보의 흐름을 조절하게 된다. 이러한 과정을 거쳐 LSTM은 긴 순차 데이터(sequential data)에 대해 RNN보다 더 나은 예측을 제공한다. 과거의 관련 없는 정보를 잊을 수 있게 하는 네트워크 구조로 이루어져 있으며, RNN에서 문제점으로 언급되는 기울기 소실 문제가 해결된다.

LSTM은 각 메모리 셀은 세 개의 시그모이드 층과 하나의 탄젠트층으로 구성된다(Mehtab et al., 2020). LSTM의 구조를 구체적으로 살펴보면, 입력 게이트는 입력 데이터의 중요도를 판단하여 얼마나 받아들일지 결정한다. 망각 게이트는 이전 셀 상태를 얼마나 유지할지를 결정하며, 출력 게이트는 최종 출력 값을 조절한다.

입력 게이트를 수식으로 표현하면 수식 (8)과 같다.

$$i_t = \text{sigmoid}(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (8)$$

이때 LSTM 각 게이트에서의 시그모이드 함수를 $\text{sigmoid}(x)$ 라고 정의한다. 입력게이트는 네트워크의 현재 상태에 입력으로 작용하는 새로운 정보를 제어하며, 이는 현재 입력 x_t 를 보유하고 이를 셀 상태 C_t 에 전달하여 중요하지 않은 내용이 메모리 셀에 들어가는 것을 방지한다. 입력 게이트에는 두 가지 기능이 존재한다. 첫 번째, 셀이 업데이트 해야 할 상태를 찾고, 업데이트된 값은 시그모이드 층에 의해 선택된다. 두 번째 기능은 셀 상태가 얼마나 업데이트 되는지를 결정한다.

수식 (9)는 셀 상태 업데이트를 나타내는 식이다.

$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \quad (9)$$

$\tanh$ 는 하이퍼탄젠트(Hyperbolic Tangent) 함수이며, $\tilde{C}_t$ 는 새로운 정보가 얼마나 추가될지를 제어하기 위해 탄젠트 층을 통해 생성된다.

망각 게이트를 식으로 표현하면 수식 (10)과 같다.

$$f_t = \text{sigmoid}(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (10)$$

망각 게이트는 LSTM 유닛에서 삭제될 셀 상태 정보를 결정한다. 이는 과거의 불필요한 기억을 제거하고 현재 상황에 관련된 지식만 유지하기 위해 사용된다. 메모리 셀은 이전 시점의 출력 h_{t-1} 과 현재 시점의 외부 정보 x_t 를 입력으로 받아, 이를 긴 벡터 $[h_{t-1}, x_t]$ 로 결합하고 시그모이드 변환을 통해 망각 게이트를 형성한다. W_f 와 b_f 는 각각 망각 게이트의 가중치 행렬과 바이어스를 나타낸다. 망각 게이트의 주요 기능은 이전 시간의 셀 상태 C_{t-1} 이 현재 시간의 셀 상태 C_t 에 얼마나 보존되는지를 기록하는 것이다.

새로운 셀 상태를 나타내는 식은 수식 (11)과 같다.

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \tilde{C}_t \quad (11)$$

출력게이트를 수식으로 표현하면 수식 (12)와 같다.

$$o_t = \text{sigmoid}(W_o \cdot [h_{t-1}, x_t] + b_o) \quad (12)$$

출력게이트는 지정된 시간에 네트워크의 출력을 제공하는 역할을 한다. 출력은 현재 상태에 대해 모델이 계산한 예측 값으로 간주될 수 있다.

셀 출력 식은 수식 (13)과 같이 정의된다.

$$h_t = o_t \cdot \tanh(C_t) \quad (13)$$




Figure 4. LSTM structure

<Figure 4>는 본 연구에서 사용하는 LSTM(Long Short-Term Memory) 모델의 구조를 보여준다. 모델의 각 계층을 보여주며 그 입력 차원과 연관되어 있음을 보여준다. 본 연구에서 사용될 LSTM 모델의 입력의 배치 크기는 가변적이지만 특징 차원은 고정되어 있다. <Figure 4>를 통해 LSTM 모델 상에서 데이터가 어떻게 흐르는지와, 각 계층이 입력 데이터를 어떻게 변환하여 다음 계층으로 전달하는지에 대하여 이해할 수 있다.

LSTM은 4개의 상호작용하는 층을 가진 RNN보다, 향상된 셀의 구조로 이루어져 있기 때문에 시퀀스 예측에 이상적임을 알 수 있다(Struga and Qirici, 2018). 위 구조를 통해 LSTM은 장기 의존성을 효과적으로 학습할 수 있으며, RNN보다 긴 시퀀스의 시계열 데이터에 대해 더 원활한 학습을 수행할 수 있다. 비트코인의 주간 수익률 변동성 예측에 LSTM 모델을 적용하는 연구는 비트코인의 시계열 데이터를 학습하여 변동성을 예측하는 데 초점을 맞춘다. 수집한 비트코인의 가격 데이터는 시퀀스가 길고 변동성이 크기 때문에 전통적인 RNN 모델보다 장기 의존성을 더 잘 학습하는 LSTM모델이 더 적합하다고 판단된다. LSTM 모델을 사용하면 비트코인 가격의 복잡한 시계열 패턴을 포착하고, 이를 기반으로 정확한 예측을 수행할 수 있다.

3.5 LSTM과 금융 시계열모형들을 이용한 통합모델 제안




Figure 5. LSTM-GARCH-EGARCH structure

본 연구에서는 두 가지 GARCH 유형 모델(GARCH, EGARCH)와 하나의 딥러닝 모델 (LSTM)을 사용하여 비트코인의 수익률 변동성 예측을 모델링한다. 먼저, GARCH(1,1) 모델로부터 변동성 예측 결과값을 얻고, 딥러닝 모델의 입력변수로 사용한다. 그 후 GARCH 유형 모델과 EGARCH 모델을 각각 LSTM 모델과 결합하여 비트코인의 수익률 변동성 예측을 개선한다. 구체적인 모델은 GARCH 모델에 딥러닝 모델을 결합한 경우 (GARCH-LSTM), EGARCH 모델에 딥러닝 모델을 결합한 경우 (EGARCH-LSTM), GARCH 모델, EGARCH 모델 그리고 딥러닝 모델을 결합한 경우 (GARCH-EGARCH-LSTM)이다. 대표적으로 이 3가지의 모델을 기존 데이터셋에 맞추어 사용한다. 통합 모델은 변동성 클러스터링, 급침도(leptokurtosis) 및 수익률의 레버리지 효과를 보다 효과적으로 포착할 수 있다. <Figure 5>을 보면, 본 연구에서는 GARCH 모델을 통해 예측된 변동성과 EGARCH 모델을 통해 예측된 변동성을 LSTM 모델의 입력으로 사용함과 동시에, 비트코인의 가격 데이터, 경제지표 변수 (KOSPI200 지수 변동성, VIX 지수 변동성, 원-달러 환율 변동성) 와 같은 다른 입력 변수들과 함께 더 나은 변동성 값을 예측할 수 있게 한다.

선행논문에서는 각 모형들의 학습능력과 변동성 예측능력에 대한 장단점을 제시함과 동시에 여러 모형들을 통합하는 것이 예측 능력 향상에 도움이 된다고 언급한다(Kim and Won, 2018). 인공지능망 모형에 입력변수로 GARCH, EGARCH와 같은 계량 경제모델의 모수를 사용해 융합시키는 것이 그 방식이다. 변동성 군집현상과 급침도 정보를 잡아내는 GARCH 모형과, GARCH 모형의 단점을 보완하고 레버리지 효과를 반영하는 EGARCH 모형을 LSTM 모형과 융합하여 모델을 구축한다.

3.6 평가지표 및 측정

3.6.1 Root Mean Squared Error (RMSE)

RMSE는 예측 모델의 성능을 평가하는 대표적인 지표로, 실제 값과 예측 값 간의 차이를 제곱한 후 평균을 내고, 그 값을 다시 제곱근한 것이다. RMSE는 모델의 예측 오차의 크기를 직관적으로 이해할 수 있는 지표이다. RMSE에 관한 수식은 수식 (14)와 같다.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (14)$$

RMSE 값이 작을수록 모델의 예측 성능이 좋다고 판단한다. 특히 RMSE는 오차가 클 때 더 큰 페널티를 주기 때문에, 큰 오차를 내는 모델을 잘 구분할 수 있는 지표로 볼 수 있다.

3.6.2 HMAE (Heteroscedastic Mean Absolute Error)

본 연구에서는 모델의 예측 성능을 평가하기 위해 비선형 손실함수인 HMAE를 평가지표로 사용한다. 이는 Heteroscedasticity(이분산성)를 고려하여 오차를 계산한다. HMAE는 예측 오차의 절대값을 예측 오차의 분산의 제곱근으로 나누어 계산한다. 이 방식은 데이터의 분산이 클 때 작은 오차를 허용하는 반면, 분산이 작을 때 큰 오차에 대해 더 큰 페널티를 준다. HMAE에 관한 수식은 수식 (15)와 같다.

$$HMAE = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{\sqrt{\sigma^2}} \quad (15)$$

오차의 분산 σ^2 은 수식 (16)와 같이 정의된다.

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 - \left(\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i) \right)^2 \quad (16)$$

n 은 샘플 외 크기 (out-of-sample size) 를 나타내며, y_i 는 실현 변동성 (observed realized volatility), $\hat{y}_i$ 는 예측된 실현 변동성 (forecasted realized volatility)을 의미한다.

HMAE는 데이터의 이분산성을 고려하므로 다양한 분산을 갖는 데이터셋에서도 균형 잡힌 평가를 지표이다. 이를 본 연구에서 사용하여 모델의 상대적 중요성과 성능을 평가한다.

3.6.3 역사적 변동성

역사적 변동성은 과거의 데이터를 기반으로 하여 변동성을 측정하는 방법이다. 이는 특정 기간 동안 자산 가격의 표준 편차를 계산함으로써 얻어진다. 본 연구에서는 수익률의 표준 편차를 계산하여 주간 변동성을 추정한다.

d 기간 동안 데이터를 수집하고 i 번째 기간의 수익률인, R_i 와 수익률의 평균 R 을 계산한다. 이를 이용하여 역사적 변동성을 계산하는 식은 수식 (17)과 같다.

$$HV = \sqrt{\frac{1}{d-1} \sum_{i=1}^n (R_i - R)^2} \quad (17)$$

4. 실험 및 평가

본 연구에서는 LSTM 기반 모델의 비트코인 역사적 변동성 예측 성능 개선 방법을 연구한다. 먼저, 수익률 변동성 예측력을 향상시키는 경제 지표 및 경제 지표 조합을 찾기 위해, 경제 지표를 추가한 후의 모델의 예측 성능 개선 여부를 평가한다. 이후 추가적인 변동성 예측력 개선을 위해, LSTM과 다중 GARCH-type 모델을 통합한 모델에서의 변동성 예측력이 향상되었다는 연구(Kim and Won, 2018)에 기반하여 모델에 사용되는 변수 간의 상관관계를 분석한 뒤, LSTM 단일 모델과 GARCH, EGARCH 모형을 복합적으로 합성한 통합 모델을 구축한다. 구축한 모델이 기존 단일 모델 대비 예측력 개선이 실제로 존재하는지 검증하는 연구를 수행한다. LSTM 기반의 단일 모델과 통합 모델에서, 경제지표를 제외한 GARCH(1,1) 모델의 예측값만을 입력변수로 추가한 모델을 기존 모델로 정의한다.

분석 데이터

설명변수로써는 KOSPI200 지수 변동성, VIX 지수 변동성 및 원-달러 환율 변동성을 활용하고, GARCH(1,1) 및 EGARCH(1,1) 모형의 조건부 변동성, 그리고 과거 일주일간의 데이터를 이용하여 GARCH(1,1)으로 현재의 변동성을 예측한 변수를 LSTM 모델의 입력 변수로 설정한다. 훈련 데이터셋은 2020년 1월 1일 1시부터 2022년 12월 31일 21시까지의 데이터, 검증 데이터셋은 2023년 1월 1일 1시부터 2023년 12월 31일 21시까지의 데이터이며, 테스트 데이터셋은 2024년 1월 1일 1시부터 4월 9일 5시까지의 데이터로 구성하였다.

딥러닝 단일 모델

LSTM 모델은 일주일 간의 역사적 변동성을 예측하도록 설계하였으며, 2개의 은닉 층과 최종 예측 값을 반환하는 Dense 층을 추가하였다. 손실함수로써는 Adam, 평가 매트릭으로는 RMSE를 사용한다. LSTM 모델의 구성은 다음과 같다. 2개의 은닉 층의 unit 수는 각각 500으로 고정하였으며, 학습률의 경우 하이퍼 파라미터 과정을 거쳐 도출된 최적 값인 0.0001을 사용하였다. Epoch 수는 100으로 고정되 과적합을 방지하기 위하여 모델 학습의 극소점에 도달할 경우 조기에 학습을 중단하도록 Callback을 추가하였다. 따라서 시행마다 에포크가 다름을 확인할 수 있다.

딥러닝 통합 모델

앞서 정의한 딥러닝 단일 모델(LSTM)에 GARCH(1,1), EGARCH (1,1) 모델의 조건부 변동성을 각각 추가하여 LSTM-GARCH, LSTM-EGARCH 모델을 구축하고, GARCH(1,1), EGARCH (1,1) 모델의 조건부 변동성을 함께 추가한 LSTM-GARCH-EGARCH 모델을 구현하여 딥러닝 통합 모델로 정의하였다.

본 연구에서는 LSTM 기반의 단일 모델 및 통합 모델을 포함한 총 4종류의 모델에 대한 변동성 예측 성능을 평가하고자 한다. 실험에 사용되는 모델은 <Table 5>에서 제시하는 바와 같다.

Table 5. An overview of the LSTM-based model

Model	Discription
LSTM	Single Neural Network Model
LSTM-GARCH	LSTM Model with GARCH(1,1) Volatility Forecast as Explanatory Variables
LSTM-EGARCH	LSTM Model with EGARCH(1,1) Volatility Forecast as Explanatory Variables
LSTM-GARCH-EGARCH	LSTM Model with GARCH(1,1) and EGARCH(1,1) Volatility Forecasts as Explanatory Variables

4.1 모델 별 경제 지표 설명변수 투입 여부에 따른 예측 성능 개선 평가

4.1.1 LSTM 단일 모델

4.1.1에서는 경제 지표 설명변수의 추가가 LSTM 단일 모델의 예측 성능을 개선하는지 검증하는 것을 목표로 한다.

Table 6. Comparison of LSTM single models based on different combinations of economic indicators

Input factors (vol) Statistical performance	None	KOSPI2 00	CBOE_ VIX	USD_K RW	KOSPI2 00 & CBOE_ VIX	KOSPI2 00 & USD_K RW	CBOE_ VIX & USD_K RW	All
RMSE	0.00378	0.00405	0.00314	0.00373	0.00227	0.00438	0.00316	0.00360
HMAE	1.20	1.15	0.934	1.14	1.13	1.23	0.923	1.01

<Table 6>는 LSTM 단일 모델에 대한 각 설명 변수 추가 시의 성능 평가 결과이다. 테이블의 None 조건은 사전에 정의한 기준 모델에 해당하며, 기준 모델에 추가로 포함되는 경제 지표 변동성을 열 제목에 기재하였다. RMSE를 성능 지표로 하였을 때, KOSPI200 지수 변동성과 VIX 지수 변동성이 함께 추가된 모델의 예측 성능이 가장 우수하게 나타났으며, 기준 모델 대비 39.9% 성능 향상을 보였다.

HMAE 평가 지표 기준 VIX 지수 변동성과 원-달러 환율 변동성이 함께 추가된 모델에서 가장 우수한 성능을 보였으며 기준 모델 대비 22.8% 개선됨을 확인할 수 있다. 대체로 기본 모델에 1가지 이상의 경제지표를 설명변수로 추가한 모든 시행에서 예측 성능이 개선되는 경향을 확인할 수 있었다. 그러나 KOSPI200 지수 변동성을 설명변수로 추가하였을 때에 HMAE 측면에서 성능이 약 4% 개선되었으나, RMSE 측면에서 7.14%의 성능 저하가 존재하였다. 이는 경제 지표 변수 추가로 전반적인 예측 정확도는 향상되었지만 큰 오차값이 존재하여 특정 평가지표 기준의 성능 저하로 이어졌을 가능성을 나타낸다. 더불어 해당 KOSPI200 지수 변동성과 원-달러 환율 변동성을 함께 모델의 설명변수로 추가했을 때에 RMSE 기준 15.9% 성능 저하 및 HMAE 기준 2.50% 성능 저하가 나타났다. 따라서 LSTM 기준 모델의 경우, KOSPI 200 지수 변동성은 모델 예측 성능 개선에 기여하지 못한다 판단할 수 있으며, 경제지표 설명변수의 기여도는 원-달러 환율 변동성, VIX 지수 변동성 순이라 할 수 있다.

위 내용을 정리 및 요약하여, 입력 변수별 기준 모델 대비 성능 개선률을 <Table 7>와 같이 표현하였다.

Table 7. Model performance improvement rates with the addition of each explanatory variable

Input factors (vol) Improvement rate (%)	RMSE	HMAE
None	-	-
KOSPI200	-7.14	4.17
CBOE_VIX	16.9	22.2
USD_KRW	13.2	5.00
KOSPI200 & CBOE_VIX	39.9	5.83
KOSPI200 & USD_KRW	-15.9	-2.50
CBOE_VIX & USD_KRW	16.4	22.8
All	4.76	15.8

4.1.2 LSTM 기반 모델 전체

4.1.2에서는 경제 지표 설명 변수의 추가가 LSTM 단일 모델 및 통합 모델의 예측 성능을 개선하는지 총체적으로 검증하는 것을 목표로 한다. <Figure 6>에서는 모델에 사용한 변수간의 상관관계를 파악하고자 상관 분석을 수행하였고 그 결과를 가시화하였다.




Figure 6. Correlation matrix

GARCH 및 EGARCH로부터 도출된 조건부 변동성은 종속변수와 0.5 이상의 상관계수 값을 가지므로, 해당 변수와 종속변수 간의 상관관계가 존재함을 가정할 수 있다. 따라서 LSTM 단일 모델의 예측력 향상을 시도하기 위해 해당 변수를 통합한 LSTM-GARCH, LSTM-EGARCH 모델을 구축하였다. 더불어 GARCH, EGARCH 변수 간의 상관 계수는 0.97로, 큰 상관성을 보이고 있음을 확인할 수 있다. 본 논문에서는 GARCH, EGARCH에서 도출된 조건부 변동성을 동시에 활용할 경우 단일 모델의 예측 성능이 개선될 가능성에 기반하여, LSTM-GARCH-EGARCH 모델을 추가로 구축해 실험을 진행하였다. 모델별 경제 지표 포함 여부에 따른 성능 비교 결과는 <Table 8>와 같이 제시할 수 있다.

Table 8. Performance evaluation of models with and without economic indicators

Model	RMSE	HMAE
LSTM	0.00378	1.20
LSTM (with economic indicators)	0.00360	1.01
LSTM-GARCH	0.00190	1.47
LSTM-GARCH (with economic indicators)	0.00209	1.41
LSTM-EGARCH	0.00177	1.06
LSTM-EGARCH (with economic indicators)	0.00252	1.61
LSTM-GARCH-EGARCH	0.00182	1.29
LSTM-GARCH-EGARCH (with economic indicators)	0.00120	0.775

LSTM 단일 모델과 LSTM-GARCH-EGARCH 통합 모델에서는 경제 지표 추가 시에 RMSE, HMAE가 감소하며 예측 성능이 각각 RMSE 기준 4.17%, 34.1% 향상됨을 확인할 수 있었다. 이와 달리, LSTM-EGARCH 모델에서는 경제지표 변수 추가 시 RMSE, HMAE 기준 성능이 저하하였고, RMSE 기준 42.4% 저하함을 확인하였다. LSTM-GARCH 모델은 경제지표 변수를 추가할 경우, HMAE 측면에서 성능이 개선되었으나 RMSE 측면에서 성능이 저하되었다. 이는 경제지표 추가로 전반적인 예측 정확도는 향상되었지만 큰 오차값이 발생하였을 가능성을 나타낸다. 즉, 모델 복잡성 증가로 인해 과적합이 발생하여 이와 같은 결과가 도출되었을 가능성이 존재한다. 따라서, 모델 선택 시 경제 지표 변수의 활용 여부를 고려해야 한다. 모델 유형에 따라 경제 지표 변동성을 추가하는 것이 성능 향상에 도움이 될 수 있으나, 한편으로는 모델 복잡도 증대로 과적합 문제가 발생해 예측 성능 저하로 이어질 수 있다는 결론을 도출할 수 있다.

4.2 모델 간 변동성 예측 성능 평가

4.2에서는 동일한 조건에 대한 서로 다른 모델 간의 변동성 예측 성능을 비교 분석하는 연구를 수행한다. 이후 동일 파라미터 조합에 대한 최적의 변동성 예측력을 지니는 모델을 찾는 실험을 수행한다. 실험에서 설계한 LSTM 기본 모델 구조를 활용하되, 특정 파라미터를 고정하여 동일 조건 하에 모델들 간의 변동성 예측 성능을 평가했다. 고정된 파라미터는 에포크와 배치 사이즈이며 동일 조건 하에서 모델별 성능을 비교하였다. 고변동성 구간은 금융 시장의 불안정성이나 예측 불가능한 시장 상황에 의해 변동성이 높게 발생하는 구간으로 예측이 어려운 경향이 존재하며, 저변동성 구간은 상대적으로 시장이 안정적인 구간으로 일반화된 예측 성능 평가가 가능한 구간으로 판단한다. 따라서 본 연구에서는 이동 표준편차의 중간값에 해당하는 0.010을 기준으로 하여, 0.010 이상일 경우 고변동성 구간, 0.010 이하일 경우 저변동성 구간으로 구분하였다. 개별 모델의 고변동성 구간, 저변동성 구간, 그리고 전체 구간에 대한 예측 성능 평가 결과는 <Table 9>와 같다.

Table 9. Statistical performances for each model based on volatility range

Volatility Range Statistical Performance	Low		High		Entire	
	RMSE	HMAE	RMSE	HMAE	RMSE	HMAE
LSTM	0.00459	1.94	0.00152	0.833	0.00360	1.01
LSTM-GARCH	0.00267	1.55	0.0151	1.78	0.00209	1.41
LSTM-EGARCH	0.00167	1.63	0.00333	2.81	0.00252	1.61
LSTM-GARCH-EGARCH	0.00097	0.892	0.00144	0.893	0.00120	0.775




Figure 7. Target value vs. Predicted target value plot for LSTM model




Figure 8. Target value vs. Predicted target Value plot for each hybrid model

<Figure 7>, <Figure 8>에서 Time series는 시간 흐름에 따른 실제 역사적 변동성을, Time series를 제외한 모든 선 그래프는 범례에 표기된 모델로부터 도출된 변동성 예측값을 표현한 것이다. <Figure 7>에서는 LSTM의 변동성 예측값을 실제 계산된 변동성과 비교하고 있는데, 실제 변동성의 큰 변화 추이를 반영하지 못하고 기존 패턴의 흐름을 지속하고 있음을 확인할 수 있다. 따라서 HMAE는 비교적 준수하나 RMSE에서 큰 오차율이 발생하여 예측 성능이 추가 개선될 여지가 있다고 판단할 수 있다. <Table 9> 에서, 전체 구간과 고변동성 구간, 그리고 저변동성 구간에 대해 LSTM 단일 모델 대비 성능 개선율이 가장 높은 모델은 LSTM-GARCH-EGARCH 통합 모델임을 확인할 수 있다. 전체 구간에서의 해당

통합 모델은, 단일 모델 대비 RMSE 및 HMAE 기준 각각 66.7%, 30.3% 성능 향상을 보였다. <Figure 7> 대비 <Figure 8>에서는, LSTM 모델에 GARCH와 EGARCH의 변동성 모델링 능력을 결합한 모든 혼합 모델을 활용함으로써 보다 정교한 변동성 예측을 수행하고 있음을 확인할 수 있다. 이는 전반적인 예측 성능이 향상되어 역사적 변동성의 큰 변화폭을 변동성 예측에 보다 잘 반영하고 있음을 시사한다. 따라서 GARCH 및 EGARCH 모형과 LSTM 모델을 통합하는 시도가 예측 성능 개선을 위한 유의미한 시도였음을 증명할 수 있다.

<Figure 8>에서 표현된 통합 모델의 전체 구간에 대한 변동성 예측 결과를 개별화하여 <Figure 9>, <Figure 10>, <Figure 11>에서 제시한다.




Figure 9. Volatility prediction results (LSTM-GARCH model)




Figure 10. Volatility prediction results (LSTM-EGARCH model)




Figure 11. Volatility prediction results (LSTM-GARCH-EGARCH model)

4.3 모델별 입력변수 조합에 따른 예측 성능 평가 및 최적 조합 제안

해당 실험에서는 추가적인 모델 성능 개선을 위해 개별 통합 모델에 대한 예측 성능을 최적화하는 설명변수 조합을 찾는 것을 목표로 연구를 수행한다. 먼저 경제지표의 예측 성능 개선에 대한 기여도를 중점적으로 평가하고자 Predicted_volatility 입력 변수를 추가한 모델을 기존 모델로 정의하여 성능 평가 및 개선을 평가를 진행한 후, 개별 경제 지표의 모델의 예측 성능에 대한 기여도를 확인하였다. 이후 Predicted_volatility 변수의 예측 성능 개선력을 평가하고자, 입력 변수에서 Predicted_volatility를 제외한 후 앞선 시행과 동일한 방법을 통해 최적 입력 변수를 제시한다.

4.3.1 LSTM-GARCH 모델

Table 10. Statistical performance results for all combinations of explanatory variables

Input Factors (vol) Statistical performance	None	KOSPI200	CBOE_VIX	USD_KRW	KOSPI200, CBOE_VIX	KOSPI200, USD_KRW	CBOE_VIX, USD_KRW	All
RMSE	0.00190	0.00158	0.00143	0.00118	0.00126	0.00208	0.00127	0.00209
HMAE	1.472	1.09	1.03	0.806	0.859	1.38	0.814	1.41

<Table 10>은, 특정 파라미터 조건 하에서 경제 지표를 조합 가능한 모든 경우의 수에 맞게 추가하였을 때의 결과를 나타낸 것으로, 원-달러 환율 변동성만이 설명변수로 추가된 조건 하에서 RMSE 및 HMAE가 가장 우수하였다. 해당 모델에서 단일 경제지표의 추가는 성능 개선에 기여하였고, 그 기여도는 원-달러 환율 변동성, VIX 지수 변동성, KOSPI200 지수 변동성 순임을 확인할 수 있다. 추가로 KOSPI200 지수 변동성과 원-달러 환율 변동성을 동시에 설명변수로 추가한 경우 성능 저하가 존재함을 확인하였다.

Table 11. Best predictive performance explanatory variable combination for LSTM-GARCH model based on RMSE and HMAE

Input Factors (vol) Statistical performance	KOSPI200_vol	CBOE_VIX_vol	USD_KRW_vol	Predicted_vol
RMSE	X	X	O	O
HMAE	O	O	X	X

이후 Predicted_volatility 변수의 예측 성능 개선력을 평가하고 최적 입력변수 조합을 도출하고자, 입력변수에서 해당 변수를 제외한 후 <Table 7>에서와 동일한 시행으로 성능 개선력을 검증하였다. 해당 시행에서의 최적 예측 성능은 VIX 지수 변동성과 KOSPI 200 변동성이 함께 추가된 조건이었으며 이때

의 RMSE, HMAE는 각각 0.00124, 0.776이었다. HMAE는 해당 입력변수 조합에서 가장 우수하게 나타났다. RMSE 평가지표 기준 하에, 이는 <Table 10>의 동일 조건 대비 개선된 성능을 보이지만, 앞선 시행을 통해 도출된 최적 조합 대비 예측 성능을 추가 개선하지 못함을 확인할 수 있다. 따라서 해당 모델에서 제시하는 최적의 입력변수 조합은 <Table 11>과 같다.




Figure 12. RMSE vs. epochs plot of the model that showed the best RMSE statistical performance

4.3.2 LSTM-EGARCH 모델

Table 12. Statistical performance results for all combinations of explanatory variables

Input Factors (vol) Statistical performance	None	KOSPI2 00	CBOE_ VIX	USD_K RW	KOSPI2 00, CBOE_ VIX	KOSPI2 00, USD_K RW	CBOE_ VIX, USD_K RW	All
RMSE	0.00177	0.00199	0.00181	0.00176	0.00163	0.00366	0.00320	0.00252
HMAE	1.06	1.13	0.0892	0.961	0.948	2.24	2.08	1.61

<Table 12>는, 특정 파라미터 조건 하에서 경제 지표를 2개 조합으로 추가하였을 때의 결과를 나타낸 것이다. KOSPI200 지수 변동성, VIX 지수 변동성을 추가한 조건에서 RMSE가 가장 우수하며 기준 모델 대비 7.91% 개선되었다. HMAE는 VIX 지수 변동성을 추가한 조건에서 가장 우수한 성능을 보였으며 15.8% 개선되었다. 유의미한 성능 개선을 보인 설명변수 조합은 VIX 지수 변동성 단일, 원-달러 환율 변동성 단일, KOSPI 200 변동성과 VIX 지수 변동성 혼합 조합이 설명변수에 추가된 조건이었다. 해당 모델에서 단일 경제지표의 RMSE 기준 성능 개선을 기여도는 원-달러 환율 변동성에 한정됨을 확인할 수 있다.

Table 13. Best predictive performance explanatory variable combination for LSTM-EGARCH model based on RMSE and HMAE

Input Factors (vol) Statistical performance	KOSPI200_vol	CBOE_VIX_vol	USD_KRW_vol	Predicted_vol
RMSE	O	O	X	O
HMAE	X	O	X	X

<Table 13>은 해당 모델에서 제시하는 최적의 입력변수 조합이다. Predicted_volatility 변수를 입력변수에서 제외한 후 <Table 12>에서와 동일한 시행으로 성능 개선력을 검증하였다. 해당 시행에서의 최적 예측 성능은 VIX 지수 변동성만이 포함된 조건이었으며, 이 경우 RMSE, HMAE는 각각 0.0021, 1.08이었다. 이는 <Table 12>의 최적 조합 및 동일 조건 대비 저하된 예측 성능을 보이므로, Predicted_volatility 변수를 추가하는 것이 실제로 모델 성능 개선에 기여한다는 결과를 도출할 수 있다.




Figure 13. RMSE vs. epochs plot of the model that showed the best RMSE statistical performance

4.3.3 LSTM-GARCH-EGARCH 모델

Table 14. Statistical performance results for all combinations of explanatory variables

Input Factors (vol) Statistical performance	None	KOSPI2 00	CBOE_ VIX	USD_K RW	KOSPI2 00, CBOE_ VIX	KOSPI2 00, USD_K RW	CBOE_ VIX, USD_K RW	All
RMSE	0.00182	0.00197	0.00176	0.00179	0.00192	0.00138	0.00342	0.00120
HMAE	1.29	1.25	1.25	1.31	1.23	0.876	2.55	0.775

〈Table 14〉의 결과는 특정 파라미터 조건 하에서 조합 가능한 모든 경우의 수에 맞게 경제 지표를 추가하였을 때의 결과를 나타낸 것이다. 결과적으로 모든 경제지표를 추가한 조건 하에서 예측 성능이 가장 우수하였다. 다만 VIX 지수 변동성과 원-달러 환율 변동성을 함께 설명변수로 추가했을 때에 기준 모델 대비 성능이 큰 폭으로 저하됨을 확인할 수 있었고, 그 이외의 조합에서는 성능이 개선되는 경향이 존재하였다. 해당 모델에서 단일 경제지표의 기여도는 원-달러 환율 변동성, VIX 지수 변동성 순이었다. KOSPI200 지수 변동성만을 설명변수에 추가한 경우 RMSE 기준 성능이 저하되었으므로 모델 성능 개선에 기여하였다 판단하기 어렵다. 경제지표 조합에 따라 성능이 크게 저하되기도, 개선되기도 하는 결과가 나타났다.

Table 15. Best predictive performance explanatory variable combination for LSTM-GARCH-EGARCH model based on RMSE and HMAE

Input Factors (vol) Statistical performance	KOSPI200_vol	CBOE_VIX_vol	USD_KRW_vol	Predicted_vol
RMSE	O	O	O	O
HMAE	O	O	O	O

Predicted_volatility 변수를 입력변수에서 제외한 후 성능 개선력을 검증한 결과, 해당 시행에서의 최적 예측 성능은 원-달러 환율 변동성과 VIX 지수 변동성이 함께 포함된 조건이었으며 이때의 RMSE, HMAE는 각각 0.00127, 0.814이었다. 이는 〈Table 14〉의 최적 조합 대비 적은 예측력 개선을 보이므로, 최적의 입력변수 조합은 〈Table 15〉와 같이 제안할 수 있다.




Figure 14. RMSE vs. epochs plot of the model that showed the best RMSE statistical performance

최종적으로, 모델별로 RMSE 기준 예측 성능 개선에 최대로 기여한 입력변수 조합은 다음과 같이 제시할 수 있다.

Table 16. Best predictive performance explanatory variable combination for all models based on RMSE

Model \ Input Factors (vol)	KOSPI200_vol	CBOE_VIX_vol	USD_KRW_vol	Predicted_vol
LSTM	O	O	O	O
LSTM-GARCH	X	X	O	O
LSTM-EGARCH	O	O	X	O
LSTM-GARCH-EGARCH	O	O	O	O

<Table 16>에 기반해, 모든 모델이 공통적으로 Predicted_volatility 변수가 추가된 조건 하에서 최적의 예측 성능을 보임을 확인할 수 있다. 즉, Predicted_volatility 변수가 실제 모델 예측 성능 개선에 기여할 가능성이 높다 판단할 수 있으며, 모두 기본 모델 대비 1가지 이상의 경제지표를 포함했을 때에 예측 성능이 개선되었다. 더불어 모델별 예측 성능을 최적화하는 설명 변수 조합이 동일하지 않은 이유에는, 설명변수 간 상관관계에 따른 성능 저해 및 개선이 이루어진 데에 원인이 있다고 판단할 수 있다.

5. 결과

본 연구에서는 다음과 같은 세 가지의 세부 실험을 수행하였다. 첫째, LSTM 단일 모델에 설명변수를 추가하여 예측 성능 개선 여부를 검증하였다. VIX 지수, KOSPI200 지수, 원-달러 환율 변동이 국내 비트코인 시장의 변동성에 영향을 줄 것이라는 가정에 기반해, 인공신경망 단일 모델에 해당 경제 지표의 변동성을 설명변수로 추가하여 변동성 예측 개선력을 검증하였다. 둘째, 동일한 파라미터 조합 내의 서로 다른 모델 간 변동성 예측 성능을 평가하였다. LSTM 모델과 GARCH, EGARCH 모형의 혼합 모델을 구축하여 각 모델의 변동성 예측 성능을 평가하였다. 셋째, 개별 모델들 간의 변동성 예측력을 최적화하는 설명변수를 추정하는 예측 성능 평가를 수행하였다.

경제 지표가 모델의 설명력과 상관관계가 존재하는지를 검증하고자 RMSE, HMAE를 계산하여 이분산성이 존재하는 데이터 상의 예측 성능 평가를 수행한 결과, 대부분의 모델에서 3가지 설명변수를 모두 추가한 경우에 모델 성능이 개선되는 것을 확인할 수 있었다. 이는 3가지 설명변수가 비트코인 자산 변동성과의 상관관계가 존재할 수 있음을 시사한다. 두 번째 실험에서는 LSTM-GARCH-EGARCH 모델의 예측 성능이 동일 조건 하, 그리고 모든 변동성 구간에서 가장 우수하게 나타났다. 더불어 이 외의 통합 모델들 또한 LSTM 단일 모델 대비 성능이 개선됨을 확인할 수 있었다. 이는 GARCH, EGARCH 모형과의 혼합 모델이 기존 단일 LSTM 모델의 변동성 예측 성능 개선에 기여할 수 있음을 시사한다. 세 번째 실험에서, 모델의 변동성 예측력을 최적화하는 입력변수 조합은 다양하게 도출되었으나 모든 모델에서 Predicted_volatility 변수를 입력 변수에 추가할 경우에 예측 성능이 개선되는 경향이 존재하였고, 이는 LSTM 통합 모델에서 Predicted_volatility 변수 추가가 예측력 개선에 기여할 수 있음을 보여준다.

본 연구는 현재 시점 기준 일주일 간의 이동 표준편차를 예측하고, LSTM 모델의 장기기억 특성을 활용하여 비트코인 시장의 변동성을 분석하는 데 중점을 두고 있다. 본 연구는 4시간 단위의 고빈도 데이터를 활용해, 비트코인 자산의 변동성에 영향력이 있는 경제 지표의 영향력을 평가하고, 다양한 통합 모델을 구축하여 개별 모델마다 예측 성능을 개선할 수 있는 적절한 설명변수 조합을 제시한 데에 의의가 있다. 또한 복합적인 경제 요인을 고려해 관련 경제지표를 설명변수로 추가하여 모델을 구축하고, 고변동성 및 저변동성 구간을 나눠 예측 성능 평가를 진행함으로써 더욱 심층적인 해석을 제시한 데에 의의가 있다. 이는 비트코인 시장의 복잡한 패턴을 이해하고, 보다 나은 예측 모델을 개발하는 데 기여할 수 있으리라 사료된다.

전반적으로 모든 모델에 대하여 경제지표 추가 시 성능이 개선되는 경향이 존재했으나, 특정 조건 하에서 모델에 설명변수를 추가할 시에 성능이 저하되는 현상이 존재하였다. 이는 실제로 특정 경제 지표와 비트코인 변동성 간의 상관관계가 존재하지 않거나 적을 가능성, 모델 학습에서 사용한 Callback 로직으로 인하여 로컬 미니멈에 도달하여 글로벌 미니멈 이전에 학습을 멈추었을 가능성, 또는 GARCH와 EGARCH 모형으로부터 예측된 변동성 간의 높은 상관관계로 인한 데이터 상의 다중 공선성이 변동성 예측의 과대 적합에 영향을 주었을 가능성 등이 존재한다. 따라서, 모델 파라미터를 더욱 정밀히 조정하거나, 특정 시점의 자산의 변동성을 설명할 수 있는 더욱 기여도가 높은 변수 선택, 혹은 더욱 다양한 전 세계적 시장 경제 흐름을 포착하여 모델의 설명력을 향상하는 경제지표(소비자물가지수(CPI) 등)를 추가하는 시도를 할 수 있을 것이다. 본 연구는 2020년부터의 비트코인 데이터를 사용하였으며, 이는 COVID-19가 발생한 이후의 데이터에 해당한다. 이에 COVID-19와 관련된 변수를 추가적으로 고려함으로써 변동성 예측 성능을 개선할 수 있다. 전염병, 경기 침체와 같은 특정 사건이 비트코인 변동성에 미치는 영향을 반영하는 것은 예측 모델을 더욱 정교하게 만들기 위한 추가적인 연구 과제가 될 것이다.

6. 참고 문헌

- Bollerslev, Tim, (1986), Generalized autoregressive conditional heteroskedasticity, *Journal of Econometrics, Elsevier*, col. **31**(3), 307-327.
- Daniel B. Nelson, (1991), Conditional Heteroskedasticity in Asset Returns: A New Approach, *The Econometric Society*, **59**(2), 347-370.
- Engle, R.F. (1982), Autoregressive Conditional Heteroskedasticity with Estimates of the Variance of United Kingdom Inflation *Econometrica*, *50*, 987-1007.
- Hochreiter, S., & Schmidhuber, J. (1997), Long short-term memory, *Neural Computation*, *9*(8), 1735-1780.
- Karaus, M. and Feuerriegel, S. (2017), Decision Support from Financial Disclosures with Deep Neural Networks and Transfer Learning, *Decision Support Systems*, *104*, 38-48.
- Kim, H-B., and Jung, D-S. (2022), A Study on the Characteristics of Bitcoin Price Change Using the GARCH Model, *Journal of the Korean Data Analysis Society*, **24**(2), 665-681.
- Kim, H-Y., Won, C-H. (2018), Predicting stock index volatility using LSTM and GARCH-type models, *M.S. thesis, Dept. Financial Engineering, Ajou Univ., Suwon, South Korea*.
- Lee, G-K., Cho, S-J., Min, K-S., and Yang, C-W. (2019), The Determinant of Bitcoin Prices in Korea, *Korean Journal of Securities*, **48**(4), 393-415.
- Mehtab, S. and Sen, J., (2019), A Robust Predictive Model for Stock Price Prediction Using Deep Learning and Natural Language Processing, *Proceedings of the 7th Int. Conf. on Business Analytics and Intelligence, Bangalore, India*
- Son, J-H. and Kim, J-Y. (2019), A Study in Bitcoin Volatility through Economic Factors, *The Journal of Society for e-Business Studies*, **24**(4), 109-118.
- Song, H-J., Choi, H-S., Kim, S-W., and Oh, S-H. (2019), A Study on Financial Time Series Data Volatility Prediction Method Using AI's LSTM Method, *Journal of Knowledge Information Technology and Systems*, **14**(6), 665-673.
- Struga, K., & Qirici, O. (2018), Bitcoin price prediction with neural networks, *Ceur workshop proceedings*, *2280*, 41-49.

Abstract

In this study, an integrated LSTM model was constructed and evaluated to predict the one-week moving standard deviation using Bitcoin 4-hour closing price data. The independent variables included the conditional volatilities of the GARCH(1,1) and EGARCH(1,1) models, the forecast values of the GARCH(1,1) model, and the moving standard deviation of economic indicators. The experiment was conducted in three stages: evaluating the performance improvement of the single LSTM model, comparing the performance of different models with the same parameter combination, and determining the optimal parameter combination for each model. As a result, the LSTM-GARCH-EGARCH model showed the highest performance, and it was confirmed that the optimal combination of explanatory variables differed for each model.

Keywords: Bitcoin, Volatility, LSTM, GARCH, EGARCH